

Deep Learning and Applications

Shanghai Jiao Tong University

Spring 2026

Hao Wu

Navier-Stokes 方程上的神经算子学习实验研究

王润祺

2026 年 5 月 24 日

摘要

神经算子学习旨在直接学习函数空间之间的映射，而不是仅在固定有限维向量空间中进行监督学习。本文围绕二维 Navier-Stokes 方程的流场预测任务，系统实现并比较了 Fourier Neural Operator (FNO) [1]、Deep Operator Network (DeepONet) [2]、CNN [3] 与 U-Net [4] 四类模型。其中，DeepONet 的 branch-trunk 架构参考 DeepXDE [5] 的公开实现进行修改，实验数据采用 FNO 原论文及其公开实现中使用的 Navier-Stokes benchmark 数据集 [1, 6]。任务设置为：以前 10 个时间步的涡量场作为输入，预测后续 10 个时间步的涡量演化，并以测试集相对 L_2 误差作为主要评价指标。实验结果表明，在 4000/500/500 的训练、验证、测试划分下，相比 U-Net、CNN 与 DeepONet，FNO 的测试相对 L_2 误差分别降低约 40.9%、83.3% 与 88.6%。消融实验进一步表明，将训练样本数从 200 增加到 1400 可使 FNO 的测试误差降低约 73.1%；将空间分辨率从 32×32 提高到 64×64 仅带来约 4.6% 的误差下降；将 FNO 深度从 2 层增加到 4 层可降低约 41.5% 的误差，而从 4 层继续增加到 6 层仅进一步降低约 10.9%。这些结果说明，在本任务中，FNO 的频域全局建模结构最适合 Navier-Stokes 流场预测，训练数据规模是影响泛化性能的关键因素，而单纯提高分辨率或继续加深网络存在边际收益递减。

关键词：神经算子学习；Fourier Neural Operator；DeepONet；Navier-Stokes 方程；PDE surrogate model；深度学习

第一章 引言

偏微分方程 (partial differential equations, PDEs) 广泛出现在流体力学、气象模拟、材料科学与工程仿真等问题中。传统数值方法通常需要在给定网格上逐步离散并求解方程, 虽然具有良好的物理可解释性与数值稳定性, 但在大规模参数扫描、实时预测或反问题中计算成本较高。近年来, 神经算子学习 (Neural Operator Learning) 试图直接学习从输入函数到输出函数的算子映射, 为 PDE surrogate modeling 提供了一类新的数据驱动方法。

与普通神经网络学习有限维向量映射不同, 神经算子模型的目标是学习函数空间之间的映射。给定输入函数 $a(x)$ 与目标函数 $u(x)$, 神经算子希望逼近真实算子

$$\mathcal{G}^\dagger : a(x) \mapsto u(x). \quad (1.1)$$

在时间依赖 PDE 中, $a(x)$ 可以表示历史流场, $u(x)$ 可以表示未来流场。因此, 算子学习模型不仅需要在训练网格上拟合样本, 还应当具有一定的跨样本、跨结构甚至跨分辨率泛化能力。

本文主要研究四类模型。第一类是 FNO [1], 它通过 Fourier 空间中的低频模态变换学习全局积分算子, 适合捕捉流体问题中的长程空间依赖。第二类是 DeepONet [2], 它基于算子通用逼近思想, 将输入函数编码与输出坐标编码分别交给 branch network 和 trunk network, 并通过二者组合得到输出函数值; 本文实现时参考了 DeepXDE [5] 中 DeepONet 的结构。第三类是 CNN [3], 它作为轻量卷积基线, 主要依赖局部卷积堆叠提取空间特征。第四类是 U-Net [4], 它通过 encoder-decoder 结构与 skip connection 捕捉多尺度空间信息, 是图像到图像回归任务中的强基线。

本文围绕二维 Navier-Stokes 方程上的算子学习任务进行实验研究。根据课程作业要求, 本文完成以下工作:

1. 实现并研究 FNO 与 DeepONet 两类神经算子模型, 其中 DeepONet 的 branch-trunk 结构基于 DeepXDE 公开实现进行修改;
2. 在 FNO 公开实现中的 Navier-Stokes benchmark 数据集上完成 PDE 流场预测任务;
3. 比较 FNO、DeepONet、CNN 与 U-Net 四种模型的预测性能、参数规模与训练成本;
4. 研究训练数据规模、网络深度与空间分辨率变化对 FNO 泛化性能的影响;
5. 可视化 FNO 在测试样本上的真实场、预测场与误差场, 以分析模型预测行为。

实验结果显示, FNO 在该任务上明显优于其他基线模型。相较 U-Net, FNO 的测试相对 L_2 误差降低约 40.9%, 参数量减少约 84.7%; 相较 CNN 与 DeepONet, FNO 的

误差分别降低约 83.3% 与 88.6%。这说明频域全局卷积结构对 Navier–Stokes 流场演化具有较强建模能力。相比之下，U-Net 虽然作为卷积式 encoder–decoder 模型具备较强空间建模能力，但参数量显著更大；CNN 更轻量但泛化误差较高；DeepONet 在当前规则网格、固定训练预算和实现设置下表现弱于 FNO。

第二章 问题设置与方法

2.1 Navier–Stokes 算子学习任务

本文考虑二维不可压 Navier–Stokes 方程的涡量预测任务。给定历史涡量场序列，模型需要预测未来一段时间内的涡量演化。实验数据来自 FNO 原论文及其公开代码中使用的 Navier–Stokes benchmark [1, 6]。原始数据文件为

NavierStokes_V1e-3_N5000_T50.mat,

包含 5000 条轨迹，每条轨迹在 64×64 空间网格上记录 50 个时间步的涡量场。本文保留全部 5000 条轨迹，并截取前 20 个时间步构造监督学习任务。

记输入样本为

$$X = (\omega_1, \omega_2, \dots, \omega_{10}), \quad (2.1)$$

输出目标为

$$Y = (\omega_{11}, \omega_{12}, \dots, \omega_{20}). \quad (2.2)$$

模型 f_θ 的目标是学习映射

$$f_\theta : \mathbb{R}^{10 \times H \times W} \rightarrow \mathbb{R}^{10 \times H \times W}. \quad (2.3)$$

训练与测试的主要评价指标为相对 L_2 误差：

$$\text{Rel-}L_2(\hat{Y}, Y) = \frac{\|\hat{Y} - Y\|_2}{\|Y\|_2}. \quad (2.4)$$

相比单纯的 MSE，相对 L_2 误差更适合比较不同样本尺度下的整体流场预测质量，因此本文将其作为核心指标。

2.2 Fourier Neural Operator

FNO [1] 的核心思想是用 Fourier 空间中的可学习变换近似 PDE 解算子。对于输入特征场 $v_l(x)$ ，FNO 层首先对其进行 Fourier 变换，保留有限个低频 Fourier 模态，并对这些模态施加可学习的复数线性变换，随后通过逆 Fourier 变换回到物理空间。一个典

型 FNO 层可写为

$$v_{l+1}(x) = \sigma(W_l v_l(x) + \mathcal{F}^{-1}(R_l \cdot \mathcal{F}(v_l))(x)), \quad (2.5)$$

其中 $\mathcal{F}$ 与 $\mathcal{F}^{-1}$ 分别表示 Fourier 变换和逆 Fourier 变换, R_l 是频域上的可学习权重, W_l 是物理空间中的点态线性变换, σ 是非线性激活函数。

FNO 的优势在于它不是单纯依赖局部卷积核逐层扩大感受野, 而是在每一层中直接通过 Fourier 模态建立全局空间交互。因此, 对于 Navier–Stokes 流场这类存在大尺度涡旋结构和长程空间相关性的 PDE, FNO 的结构偏置较为合适。本文实现的默认 FNO 采用 4 层 Fourier layer, 隐藏宽度为 32, 保留 12×12 个低频模态。实验中关闭 AMP, 并在 Fourier 路径中保持 float32 计算, 以避免半精度 FFT 在本地 GPU 上造成数值或兼容性问题。

2.3 DeepONet

DeepONet [2] 是一种具有明确算子学习解释的神经网络结构, 其基本思想是将输入函数和输出位置分别编码。具体而言, branch network 接收输入函数的离散观测值, trunk network 接收输出点坐标, 二者的输出通过内积组合得到目标函数在该坐标处的预测值:

$$\mathcal{G}_\theta(a)(\xi) = \sum_{k=1}^p b_k(a) t_k(\xi), \quad (2.6)$$

其中 $b_k(a)$ 是 branch network 的第 k 个输出, $t_k(\xi)$ 是 trunk network 的第 k 个输出, ξ 表示空间位置或时空位置。

本文参考 DeepXDE [5] 中的 DeepONet 设计, 对 branch–trunk 结构进行修改, 使其适配规则网格上的 Navier–Stokes 数据。branch network 对历史涡量场进行编码, trunk network 对空间网格坐标进行编码, 最后通过特征组合重构未来涡量场。DeepONet 的优点是结构上更接近一般函数空间算子近似, 特别适合处理传感器观测、非规则采样点或需要在任意坐标处查询输出的任务。但在本文的规则网格预测任务中, 它需要将高维流场压缩到 branch 表征, 再与 trunk 表征组合, 性能较大程度依赖网络容量、坐标编码方式与训练预算。

2.4 CNN 基线

CNN [3] 是本文使用的轻量卷积基线。它将 Navier–Stokes 预测看作多通道图像到图像回归任务, 即把 10 个历史时间步作为输入通道, 把后续 10 个时间步作为输出通道。CNN 通过若干残差卷积块提取局部空间特征, 并直接回归未来流场。

CNN 的优势是结构简单、参数量小、训练速度较快, 并且局部卷积对平移不变的空间模式具有较好的归纳偏置。但其局限也很明显: 普通卷积核主要捕捉局部邻域信息,

长程依赖需要通过堆叠多层卷积间接建模。对于 Navier–Stokes 方程中的全局涡旋结构和非局部动力学传播，浅层 CNN 的表达能力通常不足。因此，CNN 在本文中主要作为轻量有限维回归基线。

2.5 U-Net 基线

U-Net [4] 原本用于医学图像分割，但其 encoder–decoder 结构与 skip connection 也非常适合图像到图像的回归任务。本文将 U-Net 作为强卷积基线，用于比较神经算子结构和多尺度卷积结构在 PDE 预测任务中的差异。

U-Net 的 encoder 逐步下采样以获得大尺度上下文信息，decoder 逐步上采样恢复空间分辨率，skip connection 将浅层局部细节传递给解码端。因此，U-Net 能同时建模局部纹理和多尺度空间结构。其主要缺点是参数量较大，且本质上仍是在固定网格上学习有限维映射。相比之下，FNO 更直接地学习频域积分算子，在规则网格 PDE surrogate modeling 中通常具有更强的全局建模能力和参数效率。

第三章 实验设置

3.1 数据集来源、预处理与训练协议

本文采用 FNO 原论文及其公开实现中使用的二维 Navier–Stokes benchmark 数据集 [1, 6]。该数据集由数值方法生成，用于评估神经算子在流体动力学 PDE surrogate modeling 中的预测能力。原始文件为

NavierStokes_V1e-3_N5000_T50.mat,

其中包含 5000 条 Navier–Stokes 轨迹，每条轨迹在 64×64 空间网格上记录 50 个时间步的涡量场。实验中首先将原始 .mat 文件预处理为

NavierStokes_V1e-3_N5000_T20.npz,

即保留全部 5000 条轨迹，并截取前 20 个时间步用于监督学习任务。具体而言，前 10 个时间步作为输入，后 10 个时间步作为预测目标。

主模型比较实验采用

$$N_{\text{train}} = 4000, \quad N_{\text{val}} = 500, \quad N_{\text{test}} = 500.$$

所有模型均训练 30 个 epoch，batch size 为 8，初始学习率为 10^{-3} ，权重衰减为 10^{-4} ，学习率调度器为 cosine scheduler，最小学习率为 10^{-6} 。实验固定随机种子为 2026。训

练中根据验证集相对 L_2 误差保存最佳模型，并最终在测试集上报告结果。

消融实验包括三部分：

1. **训练数据规模**：固定模型为 FNO，比较 $N_{\text{train}} \in \{200, 500, 1000, 1400\}$ 时的性能变化；
2. **空间分辨率**：固定模型为 FNO，比较 32×32 、 48×48 与 64×64 分辨率下的性能；
3. **网络深度**：固定模型为 FNO，比较 Fourier layer 数为 2、4 与 6 时的性能。

其中分辨率与网络深度消融均采用 $N_{\text{train}} = 1000$ 、 $N_{\text{val}} = 500$ 、 $N_{\text{test}} = 500$ 的划分，以避免训练数据规模变化带来的混杂因素。

3.2 硬件与复现设置

实验在本地 GPU 环境下完成，主要硬件为 NVIDIA GeForce RTX 3060 Laptop GPU，显存为 6GB。软件环境包括 Python、PyTorch 与常用科学计算库。为了提高可复现性，代码中保存了每次实验的配置文件、最佳 checkpoint、测试指标和预测可视化结果。最终结果由清洗后的 `summary_all_clean.csv` 汇总，并按模型比较、数据规模、空间分辨率和网络深度四类实验分别生成图表。

第四章 实验结果与分析

4.1 四模型比较实验

表 4-0 给出了 FNO、DeepONet、CNN 与 U-Net 在主测试集上的结果。图 4-1 展示了四个模型的测试相对 L_2 误差，图 4-2 进一步比较了模型参数量与预测误差之间的关系。

表 4-0 四类模型在 Navier–Stokes 预测任务上的测试结果。训练、验证、测试划分为 4000/500/500。

模型	Test Rel- $L_2 \downarrow$	Test MSE $\downarrow$	Test MAE $\downarrow$	参数量	训练时间 (s)
FNO	0.005359	0.000057	0.005067	1.19M	547.3
U-Net	0.009068	0.000149	0.008305	7.77M	596.1
CNN	0.032061	0.001730	0.026645	0.078M	351.5
DeepONet	0.047125	0.003749	0.044109	0.742M	410.1




图 4-1 四类模型在测试集上的相对 L_2 误差比较。

从相对改进角度看，FNO 相比 U-Net、CNN 与 DeepONet 的测试相对 L_2 误差分别降低约

$$40.9\%, \quad 83.3\%, \quad 88.6\%.$$

这说明 FNO 在本 Navier–Stokes 预测任务上具有最强泛化性能。进一步比较参数效率，FNO 的参数量相比 U-Net 减少约 84.7%，而误差仍降低约 40.9%；训练时间相比 U-Net 也减少约 8.2%。这表明 FNO 并不是通过更大的参数规模获得优势，而是通过更适合 PDE 流场的频域算子结构获得更好的性能。

CNN 的参数量相比 FNO 更少，但其误差比 FNO 高约 498.3%。这说明在该任务中，单纯依靠局部卷积虽然计算轻量，但难以捕捉 Navier–Stokes 演化中的全局依赖。DeepONet 的参数量小于 FNO，但其误差比 FNO 高约 779.3%，说明当前 branch–trunk 实现和训练预算下，DeepONet 对规则网格流场预测的适配性弱于 FNO。需要强调的是，该结果并不否定 DeepONet 在一般算子学习问题中的价值，而是说明对于本文这种规则网格、强空间相关的 Navier–Stokes 数据，FNO 的频域归纳偏置更有效。




图 4-2 模型参数量与测试相对 L_2 误差之间的关系。横轴采用对数尺度。

图 4-2 进一步展示了精度--复杂度权衡。U-Net 具有较低误差，但参数量约为 FNO 的 6.5 倍；CNN 参数量最少，但误差显著升高；DeepONet 参数量中等，但在该设置下未能有效降低误差。因此，FNO 在误差、参数量与训练时间之间取得了最优折中。

4.2 训练数据规模的影响

为了研究训练数据规模对神经算子泛化能力的影响，本文固定模型为 FNO，并改变训练样本数。表 4-2 与图 4-3 给出了实验结果。

表 4-2 训练数据规模对 FNO 测试性能的影响。

训练样本数	Test Rel- $L_2 \downarrow$	Test MSE $\downarrow$	Test MAE $\downarrow$	训练时间 (s)
200	0.037123	0.002388	0.034544	63.3
500	0.019429	0.000668	0.018145	101.4
1000	0.013045	0.000310	0.012216	173.0
1400	0.009997	0.000190	0.009405	221.8




图 4-3 训练数据规模对 FNO 测试相对 L_2 误差的影响。

从相对变化看, 将训练样本数从 200 增加到 500 时, 测试相对 L_2 误差降低约 47.7%; 从 500 增加到 1000 时, 误差继续降低约 32.8%; 从 1000 增加到 1400 时, 误差进一步降低约 23.4%。总体而言, 从 200 到 1400, 误差降低约 73.1%。若将主模型比较实验中 4000 条训练样本的 FNO 结果作为更大数据规模参考, 则从 200 到 4000, 误差总计降低约 85.6%。

这些结果表明, 训练数据规模是影响 FNO 泛化性能的关键因素。更多 Navier–Stokes 轨迹能够帮助模型学习更稳定的函数空间映射。不过, 数据规模增大也带来计算成本上升。从 200 到 1400, 训练时间增加约 250.4%; 若扩展到 4000 条训练样本, 训练时间相对 200 条增加约 764.6%。因此, 数据规模提升带来明显精度收益, 但也存在显著计算成本。

4.3 空间分辨率的影响

为了研究输入输出空间网格分辨率对性能的影响, 本文固定模型为 FNO, 固定训练样本数为 1000, 比较 32×32 、 48×48 与 64×64 三种分辨率。结果见表 4-3 与图 4-4。

表 4-3 空间分辨率对 FNO 测试性能的影响。训练样本数固定为 1000。

空间分辨率	Test Rel- $L_2 \downarrow$	Test MSE $\downarrow$	Test MAE $\downarrow$	训练时间 (s)
32×32	0.013668	0.000340	0.012761	98.8
48×48	0.013617	0.000337	0.012741	125.4
64×64	0.013044	0.000310	0.012215	130.3




图 4-4 空间分辨率对 FNO 测试相对 L_2 误差的影响。

从相对变化看，将分辨率从 32×32 提高到 48×48 时，误差仅降低约 0.4%；从 48×48 提高到 64×64 时，误差降低约 4.2%；整体从 32×32 到 64×64 ，误差降低约 4.6%。相比训练数据规模带来的 73.1% 以上误差下降，单纯提高空间分辨率的收益明显更小。

与此同时，训练时间从 32×32 到 64×64 增加约 31.9%。因此，提高分辨率带来的精度收益并不与计算成本等比例匹配。这可能说明，在当前数据和任务中，主要流场结构已经能够在较低分辨率上被捕捉；当训练样本数固定时，更高分辨率带来的额外空间自由度并不能被模型充分利用。

4.4 网络深度的影响

为了研究 FNO 网络结构变化对性能的影响，本文改变 Fourier layer 数量，并固定训练样本数为 1000。表 4-4 与图 4-5 给出了实验结果。

表 4-4 FNO 网络深度对测试性能的影响。

Fourier 层数	Test Rel- $L_2 \downarrow$	Test MSE $\downarrow$	Test MAE $\downarrow$	参数量	训练时间 (s)
2	0.022292	0.000882	0.020554	0.598M	112.5
4	0.013045	0.000310	0.012216	1.190M	289.0
6	0.011629	0.000250	0.010955	1.782M	356.2




图 4-5 FNO 网络深度对测试相对 L_2 误差的影响。

从 2 层增加到 4 层时，FNO 的测试相对 L_2 误差降低约 41.5%，说明较浅的 FNO 容量不足，难以充分学习 Navier–Stokes 演化算子。然而，从 4 层进一步增加到 6 层时，误差仅降低约 10.9%，边际收益明显下降。总体上，从 2 层到 6 层，误差降低约 47.8%。

与此相对，参数量从 2 层到 4 层增加约 99.0%，从 4 层到 6 层继续增加约 49.7%；训练时间从 2 层到 4 层增加约 156.9%，从 4 层到 6 层增加约 23.3%。因此，增加网络深度确实可以改善性能，但收益并不线性增长。默认 4 层 FNO 在精度、参数规模和训练时间之间取得了较合理的折中。

4.5 定性预测结果

除定量指标外，本文进一步可视化 FNO 在测试集上的预测结果。每个样本均展示最后预测时间步的真实场、预测场与逐点绝对误差。图 4-6 展示了四个测试样本的预测可视化结果。




图 4-6 FNO 在测试集上的定性预测结果。每个子图包含真实场、预测场与绝对误差场。

从图 4-6 可以看出，FNO 能够较好恢复 Navier–Stokes 流场中的主要空间结构，尤其是大尺度涡旋和低频流动模式。绝对误差通常集中在局部梯度较大或涡旋边界附近的区域。这与 FNO 的建模机制相一致：频域卷积善于捕捉全局低频结构，但对高频细节和局部尖锐变化仍可能存在一定误差。结合前述定量结果，FNO 在整体流场预测上表现稳定，但进一步提升局部高频结构预测仍是后续改进方向。

第五章 讨论

5.1 不同模型的优缺点

综合实验结果，可以得到以下比较。

FNO 在 Navier–Stokes 算子学习任务上表现最好。相较 U-Net、CNN 和 DeepONet，FNO 的测试相对 L_2 误差分别降低约 40.9%、83.3% 和 88.6%。其优势来自频域全局建模能力，能够直接在 Fourier 空间中学习流场演化的低频主导结构。相比 U-Net，FNO 不仅误差更低，而且参数量减少约 84.7%，说明其具有更高参数效率。

DeepONet 具有一般算子学习解释，branch–trunk 结构适合从函数观测到函数值的学习问题。但在当前规则网格 Navier–Stokes 数据上，本文实现的 DeepONet 相比 FNO 的误差高约 779.3%。这可能与坐标编码、branch network 的输入压缩方式以及训练预算有关。对于不规则观测点、稀疏传感器或非规则输出位置，DeepONet 仍可能具有优势。

CNN 是最轻量的基线，参数量仅为 0.078M，但其误差相比 FNO 高约 498.3%。这说明局部卷积结构虽然计算高效，但对长程空间相关性建模不足，因此难以在该 PDE 预测任务中达到神经算子模型的性能。

U-Net 是较强的卷积式 encoder–decoder baseline，能够通过多尺度结构和 skip

connection 保留空间细节。在本文实验中，U-Net 的误差仅次于 FNO，但其参数量约为 FNO 的 6.5 倍。也就是说，U-Net 可以通过较大模型容量获得较强预测能力，但其参数效率不如 FNO。

5.2 泛化性能的影响因素

消融实验显示，训练数据规模是影响 FNO 泛化性能的最主要因素之一。从 200 条训练轨迹增加到 1400 条训练轨迹时，误差下降约 73.1%；若进一步参考 4000 条训练轨迹的主实验结果，则误差总下降约 85.6%。相比之下，在固定 1000 条训练轨迹时，将空间分辨率从 32×32 提高到 64×64 仅带来约 4.6% 的误差下降。网络深度实验中，从 2 层到 4 层带来约 41.5% 的误差下降，但从 4 层到 6 层仅带来约 10.9% 的额外下降。

这些结果说明，更多训练数据比单纯提高分辨率更能改善泛化性能；加深网络可以增强表达能力，但存在明显边际收益递减。在实际应用中，应根据数据规模、计算预算和精度需求选择合适的模型结构，而不是盲目增加分辨率或网络深度。

第六章 结论

本文完成了 Navier–Stokes 方程上的神经算子学习实验，系统实现并比较了 FNO、DeepONet、CNN 与 U-Net 四类模型，并进一步研究了训练数据规模、空间分辨率和网络深度对 FNO 泛化性能的影响。实验表明，FNO 相比 U-Net、CNN 与 DeepONet 的测试相对 L_2 误差分别降低约 40.9%、83.3% 与 88.6%，同时相比 U-Net 参数量减少约 84.7%。消融实验显示，将训练样本数从 200 增加到 1400 可使误差下降约 73.1%；将空间分辨率从 32×32 提高到 64×64 仅使误差下降约 4.6%；将 FNO 深度从 2 层增加到 4 层可使误差下降约 41.5%，但从 4 层进一步增加到 6 层只带来约 10.9% 的额外下降。定性预测结果进一步显示，FNO 能够较好恢复主要涡旋结构，误差主要集中于局部高频区域。

总体来看，FNO 的频域全局建模机制非常适合规则网格上的 Navier–Stokes 流场预测任务；训练数据规模是影响神经算子泛化能力的关键因素；更高分辨率和更深网络虽然可能改善性能，但其收益明显小于增加训练数据，并且会带来额外计算成本。未来可以进一步比较 Galerkin Transformer、UNO 或 Physics-informed Neural Operator 等结构，并在更长时间预测、更高雷诺数或跨分辨率泛化设置下评估模型稳定性。

参考文献

- [1] Zongyi Li, Nikola Kovachki, Kamyar Azizzadenesheli, Burigede Liu, Kaushik Bhattacharya, Andrew Stuart, and Anima Anandkumar. Fourier neural operator for parametric partial differential equations. In *International Conference on Learning Representations*, 2021.

- [2] Lu Lu, Pengzhan Jin, Guofei Pang, Zhongqiang Zhang, and George Em Karniadakis. Learning nonlinear operators via deepnet based on the universal approximation theorem of operators. *Nature Machine Intelligence*, 3:218–229, 2021.
- [3] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521:436–444, 2015.
- [4] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention*, pages 234–241, 2015.
- [5] Lu Lu, Xuhui Meng, Zhiping Mao, and George Em Karniadakis. Deepxde: A deep learning library for solving differential equations. *SIAM Review*, 63(1):208–228, 2021.
- [6] Zongyi Li. Fourier neural operator: Official implementation and benchmark datasets. https://github.com/zongyi-li/fourier_neural_operator, 2020. GitHub repository.